

# Felicidad en el mundo. Análisis de componentes principales

Julio David Ruiz Mendoza

lunes 07 de junio de 2021

## Índice

<b>1</b>	<b>Introducción</b>	<b>2</b>
<b>2</b>	<b>Lectura y preparación de datos</b>	<b>2</b>
<b>3</b>	<b>Análisis de los datos</b>	<b>3</b>
3.1	Resumen estadístico . . . . .	3
3.2	Vista de los datos . . . . .	3
3.3	Países más felices . . . . .	4
3.4	Felicidad por region . . . . .	5
<b>4</b>	<b>PCA</b>	<b>6</b>
4.1	Qué es un PCA . . . . .	6
4.2	Procedimiento . . . . .	6
4.2.1	Correlación . . . . .	6
4.2.2	Cálculo PCA . . . . .	6
4.2.3	Representación gráfica. Interpretación . . . . .	8
<b>5</b>	<b>Referencias y bibliografía</b>	<b>10</b>

# 1 Introducción

En este documento vamos a tratar un conjunto datos sobre la felicidad en distintos países alrededor del planeta. Vamos a importar el archivo y preparar el dataframe seleccionando los datos que nos sean útiles, después vamos a hacer una introducción a los datos y por último definir brevemente qué es un PCA.

He elegido este tema porque parece interesante saber los factores que influyen en la felicidad y en qué países la población es más feliz.

## 2 Lectura y preparación de datos

---

Trabajamos con el fichero: `world-happiness-report-2021.csv`  
Proveniente de la base de datos [Kaggle](#)  
Nº de observaciones: 149  
Nº de variables: 20

---

Vista de datos:

Pais	Region	Felicidad	PIB	Apoyo.social	Esp.vida	Libertad	Generosidad	Corrupcion
Finland	EUW	7.842	10.775	0.954	72.000	0.949	-0.098	0.186
Denmark	EUW	7.620	10.933	0.954	72.700	0.946	0.030	0.179
Switzerland	EUW	7.571	11.117	0.942	74.400	0.919	0.025	0.292
Iceland	EUW	7.554	10.878	0.983	73.000	0.955	0.160	0.673
Netherlands	EUW	7.464	10.932	0.942	72.400	0.913	0.175	0.338
Norway	EUW	7.392	11.053	0.954	73.300	0.960	0.093	0.270
Sweden	EUW	7.363	10.867	0.934	72.700	0.945	0.086	0.237
Luxembourg	EUW	7.324	11.647	0.908	72.600	0.907	-0.034	0.386
New Zealand	AMN	7.277	10.643	0.948	73.400	0.929	0.134	0.242
Austria	EUW	7.268	10.906	0.934	73.300	0.908	0.042	0.481
Australia	AMN	7.183	10.796	0.940	73.900	0.914	0.159	0.442
Israel	AFN	7.157	10.575	0.939	73.503	0.800	0.031	0.753

### 3 Análisis de los datos

#### 3.1 Resumen estadístico

Vamos a realizar un breve resumen de las variables numéricas que tenemos:

Tabla 3: Resumen estadístico de las variables

	Min	Q1	Mediana	Media	Q3	Max	Var
Felicidad	2.52	4.85	5.53	5.53	6.26	7.84	1.15
PIB	6.64	8.54	9.57	9.43	10.42	11.65	1.34
Apoyo.social	0.46	0.75	0.83	0.81	0.90	0.98	0.01
Esp.vida	48.48	59.80	66.60	64.99	69.60	76.95	45.73
Libertad	0.38	0.72	0.80	0.79	0.88	0.97	0.01
Generosidad	-0.29	-0.13	-0.04	-0.02	0.08	0.54	0.02
Corrupcion	0.08	0.67	0.78	0.73	0.84	0.94	0.03

#### 3.2 Vista de los datos




Figura 1: Representación de todas las variables.

No podemos ignorar que hay variables que están relacionadas de algun modo .

### PIB frente a Esperanza de vida




Figura 2: Representación del PIB frente a la esperanza de vida.

Por ejemplo en el PIB de un país y la esperanza de vida podemos suponer que tienen dependencia, más adelante veremos si es así, o por el contrario nos estamos equivocando.


### 3.3 Países más felices

Por lo general la calidad de vida será influyente en la felicidad, siendo factores como la pobreza y las guerras que afectan negativamente. En los países más felices 9 de los 10 del top se sitúan en Europa.



Fuente: The World Happiness Report 2021

Figura 3: Top 10 países más felices



Fuente: The World Happiness Report 2021

Figura 4: Top 10 países menos felices

### 3.4 Felicidad por region




Figura 5: Gráfico de barras Felicidad por region.

## 4 PCA

### 4.1 Qué es un PCA

Como hemos visto en la figura 1 hay variables que dependen de otras en cierta medida, a esto se le llama **correlación** y adopta un valor de -1 a 1. Una alta correlación en nuestro datos significa que hay redundancia en nuestros datos, es decir tenemos información repetida, que con el cambio apropiado de variables nos permitirá guardar gran porcentaje de la información con menos variables.

**PCA** (Análisis de componentes principales) es un método de análisis de datos multivariante que nos permite resumir y visualizar la información contenida en un gran conjunto de datos de variables cuantitativas.

### 4.2 Procedimiento

#### 4.2.1 Correlación

El primer paso para realizar un PCA es ver si nuestras variables pueden estar relacionadas como hemos visto anteriormente, y a continuación crear una matriz de correlaciones como la siguiente:

Tabla 4: Correlación de las variables.

	Felicidad	PIB	Apoyo.social	Esp.vida	Libertad	Generosidad	Corrupcion
Felicidad	1.00	0.79	0.76	0.77	0.61	-0.02	-0.42
PIB	0.79	1.00	0.79	0.86	0.43	-0.20	-0.34
Apoyo.social	0.76	0.79	1.00	0.72	0.48	-0.11	-0.20
Esp.vida	0.77	0.86	0.72	1.00	0.46	-0.16	-0.36
Libertad	0.61	0.43	0.48	0.46	1.00	0.17	-0.40
Generosidad	-0.02	-0.20	-0.11	-0.16	0.17	1.00	-0.16
Corrupcion	-0.42	-0.34	-0.20	-0.36	-0.40	-0.16	1.00

Factores como la riqueza, la salud y el apoyo social son los más importantes para determinar la felicidad, mientras que la generosidad y la corrupción son las menos relacionadas.

Ahora calcularemos el índice de Kaiser-Meyer-Olkin (KMO), que compara los valores de correlaciones entre pares de variables. Si el índice adopta un valor próximo a 1 será viable realizar el PCA.

```
## Kaiser-Meyer-Olkin factor adequacy
## Call: psych::KMO(r = dfn)
## Overall MSA =  0.84
## MSA for each item =
##   Felicidad          PIB Apoyo.social      Esp.vida      Libertad Generosidad
##   0.87            0.81        0.86            0.86            0.85        0.56
##   Corrupcion
##   0.78
```

El índice global es 0.84 por lo que vamos a realizar el análisis.

#### 4.2.2 Cálculo PCA

Como ya lo hemos justificado procedemos a realizar los cálculos.




Figura 6: Correlación de las variables.

Tabla 5: Autovalores y varianza acumulada por cada componente.

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	3.91	55.91	55.91
comp 2	1.29	18.42	74.33
comp 3	0.71	10.12	84.44
comp 4	0.52	7.41	91.85
comp 5	0.25	3.59	95.43
comp 6	0.19	2.76	98.20
comp 7	0.13	1.80	100.00

Lo que significa que con tan solo 3 componentes acumulamos un 84.44% de la varianza.

Scree plot




Figura 7: Gráfico de sedimentación de los autovalores

#### 4.2.3 Representación gráfica. Interpretación

Procedemos a representar el peso que tiene cada variable de las originales en las nuevas componentes y los individuos en las dos primeras dimensiones principales.

La primera dimensión está relacionada con el bienestar del individuo, y la segunda diremos que tiene que ver con lo egoísta que es la sociedad.

Se sitúan a la izquierda países del Sur de África y Sur de Asia, por media Norte de África, Latinoamérica y Este de Asia, y finalmente a la derecha se sitúan los países de Norte de América y Europa.




Figura 8: Representación variables PCA en dos dimensiones




Figura 9: Representación de los individuos

## 5 Referencias y bibliografía

- Adler, D., & Murdoch, D. (2021). *Rgl: 3D visualization using opengl.* <https://CRAN.R-project.org/package=rgl>
- Chang, W., Cheng, J., Allaire, J., Sievert, C., Schloerke, B., Xie, Y., Allen, J., McPherson, J., Dipert, A., & Borges, B. (2021). *Shiny: Web application framework for r.* <https://shiny.rstudio.com/>
- Henry, L., & Wickham, H. (2020). *Purrr: Functional programming tools.* <https://CRAN.R-project.org/package=purrr>
- Husson, F., Josse, J., Le, S., & Mazet, J. (2020). *FactoMineR: Multivariate exploratory data analysis and data mining.* <http://factominer.free.fr>
- Kassambara, A., & Mundt, F. (2020). *Factoextra: Extract and visualize the results of multivariate data analyses.* <http://www.sthda.com/english/rpkgs/factoextra>
- Lê, S., Josse, J., & Husson, F. ois. (2008). FactoMineR: A package for multivariate analysis. *Journal of Statistical Software*, 25(1), 1–18. <https://doi.org/10.18637/jss.v025.i01>
- Luque-Calvo, P. L. (2017). *Escribir un trabajo fin de estudios con r markdown.* Disponible en <http://destio.us.es/calvo>.
- M. Francisca Carreño Fructuoso, J. M. M. P., Fernando Pérez Sanz. (n.d.). *Curso online autónomo métodos de análisis de datos multivariantes.* OOR-team. <https://argos.inf.um.es/mamutCola/index.html>
- Müller, K., & Wickham, H. (2021). *Tibble: Simple data frames.* <https://CRAN.R-project.org/package=tibble>
- R Core Team. (2016). *R: A language and environment for statistical computing.* R Foundation for Statistical Computing. <https://www.R-project.org/>
- Revelle, W. (2021). *Psych: Procedures for psychological, psychometric, and personality research.* <https://personality-project.org/r/psych/> <https://personality-project.org/r/psych-manual.pdf>
- team, O. (2021). *Latex documentation.* Overleaf-team. <https://es.overleaf.com/learn>
- Thureau, S., & Husson, F. (2020). *FactoInvestigate: Automatic description of factorial analysis.* <http://factominer.free.fr/reporting/>
- Vaissie, P., Monge, A., & Husson, F. (2021). *Factoshiny: Perform factorial analysis from factominer with a shiny application.* <http://factominer.free.fr/graphs/factoshiny.html>
- Wei, T., & Simko, V. (2021a). *Corrplot: Visualization of a correlation matrix.* <https://github.com/taiyun/corrplot>
- Wei, T., & Simko, V. (2021b). *R package "corrplot": Visualization of a correlation matrix.* <https://github.com/taiyun/corrplot>
- Wickham, H. (2016). *Ggplot2: Elegant graphics for data analysis.* Springer-Verlag New York. <https://ggplot2.tidyverse.org>
- Wickham, H. (2021). *Tidyr: Tidy messy data.* <https://CRAN.R-project.org/package=tidyr>
- Wickham, H., Chang, W., Henry, L., Pedersen, T. L., Takahashi, K., Wilke, C., Woo, K., Yutani, H., & Dunnington, D. (2020). *Ggplot2: Create elegant data visualisations using the grammar of graphics.* <https://CRAN.R-project.org/package=ggplot2>
- Wickham, H., François, R., Henry, L., & Müller, K. (2021). *Dplyr: A grammar of data manipulation.* <https://CRAN.R-project.org/package=dplyr>
- Xie, Y. (2014). Knitr: A comprehensive tool for reproducible research in R. In V. Stodden, F. Leisch, & R. D. Peng (Eds.), *Implementing reproducible computational research.* Chapman; Hall/CRC. <http://www.crcpress.com/product/isbn/0D0A20%20%20%209781466561595>

- Xie, Y. (2015). *Dynamic documents with R and knitr* (2nd ed.). Chapman; Hall/CRC. <https://yihui.org/knitr/>
- Xie, Y. (2021). *Knitr: A general-purpose package for dynamic report generation in r*. <https://yihui.org/knitr/>
- Yihui Xie, E. R., Christophe Dervieux. (2021). *R markdown cookbook*. <https://bookdown.org/yihui/rmarkdown-cookbook/>
- Zhu, H. (2021). *KableExtra: Construct complex table with kable and pipe syntax*. <https://CRAN.R-project.org/package=kableExtra>

## Índice de tablas

3	Resumen estadístico de las variables . . . . .	3
4	Correlación de las variables. . . . .	6
5	Autovalores y varianza acumulada por cada componente. . . . .	7

## Índice de figuras

1	Representación de todas las variables.	3
2	Representación del PIB frente a la esperanza de vida.	4
3	Top 10 países más felices	4
4	Top 10 países menos felices	5
5	Gráfico de barras Felicidad por region.	5
6	Correlación de las variables.	7
7	Gráfico de sedimentación de los autovalores	8
8	Representación variables PCA en dos dimensiones	9
9	Representación de los individuos	9